




上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



Introduction to LLMs

马汝辉 副教授

上海交通大学

饮水思源 · 爱国荣校



④ 期末总成绩=日常出勤等（占20%）+ 期末大作业（占80%）。

④ 大作业报告要求

- 本次大作业要求学生从以下四个领域中选择一个进行深入研究并**完成综述报告**：
 - 大模型 (Large Language Models)
 - 联邦学习 (Federated Learning)
 - 无服务器计算 (Serverless Computing)
 - 量子计算 (Quantum Computing)
- 报告内容应结合课堂所学知识，并参考相关的在线资料与文献，全面梳理所选领域的基础概念、当前技术发展、应用场景、挑战与前景。
- 报告要求：
 - 字数：3000-5000字。
 - 格式：不作严格要求，得体即可（可以参考毕业论文的结构，但无需包含其中的英文部分）。
 - 参考文献：需引用至少5篇以上的相关文献，并进行恰当的文献标注。



1

Introduction

2

History&Hierarchy

3

Basic Concepts

4

Types


5

Acknowledge

01

Introduction


LLMs





什么是语言模型？

语言模型：从统计或者说统计学习的角度切入来讲这件事情，我们期望实现的是**基于给定的文本信息输入，给出对应的新的文本/符号输出**（可以是文本翻译、文本分类、文本扩写）。





什么是语言模型?

要实现这样一个任务要解决两个问题:

1) **输入序列问题**: 字符 -> 数值。

2) **输出序列问题**: 神经网络的数值类型
输出->最终字符输出。

A 4-dimensional embedding

cat =>

mat =>

on =>

1.2	-0.1	4.3	3.2
0.4	2.5	-0.9	0.5
2.1	0.3	0.1	0.4

...

...



什么是语言模型？

针对于第一个问题，其处理方式其实有很多种，比如最简单的，我们可以将输入序列进行编码，从而把字符转化为数值。

> 示例：

假设整个符号体系只有{'a','b','.'}。

输入序列是：'ab.b'

这里采用最简易的one-hot编码，总共3个字符，再加入'<begin>'和'<end>'两个字符串的起始和终止字符，其对应关系为

'<begin>':[0,0,0,0]; 'a':[1,0,0,0]; 'b':[0,1,0,0]; '.':[0,0,1,0]; '<end>':[0,0,0,1]

则输入序列可以编码为: **[[0,0,0,0],[1,0,0,0],[0,1,0,0],[0,0,0,1],[0,1,0,0],[0,0,0,1]]**

然后此序列编码可以进入神经网络进行计算。





什么是语言模型?

针对于第二个问题，同第一个问题类似，其处理方式其实有很多种，我们可以将输入序列进行编码，从而把数值转化为字符。

> 示例:

假设整个符号体系只有{'a','b','.'}。

输入序列是: 'ab.b', 期望输出序列是'b.'

$[0,0,0,0]:\text{'<begin>'}$; $[1,0,0,0]:\text{'a'}$; $[0,1,0,0]:\text{'b'}$; $[0,0,1,0]:\text{'.'}$; $[0,0,0,1]:\text{'<end>'}$;

可以构建神经网络的输出是四分类,

- 假设模型输出为 $[0,1,0,0] \rightarrow \text{'b'}$
- $\rightarrow$ 下一个输出 $[0,0,1,0] \rightarrow \text{'.'}$
- $\rightarrow$ 下一个输出 $[0,0,0,1] \rightarrow \text{'<end>'}$, 从而结束整个输出。



什么是语言模型?

语言模型 (LM) 的经典定义是一种对词元序列(token)的概率分布。假设我们有一个词元集的词汇表 V 。

语言模型 p 为每个词元序列 $x_{\{1\}}, \dots, x_{\{L\}} \in V$ 分配一个概率 (介于0和1之间的数字) : $p(x_1, \dots, x_L)$

概率直观地告诉我们一个**标记序列**有多“好 (good)”。例如, 如果词汇表为{ate, ball, cheese, mouse, the}, 语言模型可能会分配以下概率:

$$p(\text{the, mouse, ate, the, cheese}) = 0.02,$$

$$p(\text{the, cheese ate, the, mouse}) = 0.01,$$

$$p(\text{mouse, the, the, cheese, ate}) = 0.0001,$$



什么是语言模型?



$$p(\text{the, mouse, ate, the, cheese}) = 0.02,$$

$$p(\text{the, cheese ate, the, mouse}) = 0.01,$$

$$p(\text{mouse, the, the, cheese, ate}) = 0.0001,$$

例如，语言模型应该隐含地赋予"*mouse the the cheese ate*"一个非常低的概率，因为它在语法上是不正确的（**句法知识**）。


同时由于**世界知识**的存在，语言模型应该隐含地赋予"*the mouse ate the cheese*"比"*the cheese ate the mouse*"更高的概率。这是因为两个句子在句法上是相同的，但在语义上却存在差异。而语言模型需要具备卓越的语言能力和世界知识，才能准确评估序列的概率。



02

History & Hierarchy

LLMs





信息理论



语言模型的发展可以追溯到克劳德·香农，他在1948年的具有里程碑意义的论文《通信的数学理论》中奠定了信息理论的基础。在这篇论文中，他引入了用于度量概率分布的熵（Entropy）的概念：

$$H(p) = \sum_x p(x) \log \frac{1}{p(x)}$$



熵实际上是一个衡量**将样本 $x \sim p$ 编码（即压缩）成比特串所需要的预期比特数的度量**。举例来说，"the mouse ate the cheese" 可能会被编码成 "0001110101"。



熵的值越小，表明序列的结构性越强，编码的长度就越短。直观地理解， $\log(1/p(x))$ 可以视为用于表示出现概率为 $p(x)$ 的元素 x 的编码的长度。

- 例如，如果 $p(x)=1/8$ ，我们就需要分配 $\log_2(8)=3$ 个比特（或等价地， $\log(8)=2.08$ 个自然单位）。
- 需要注意的是，实际上达到香农极限（Shannon limit）是非常具有挑战性的（例如，低密度奇偶校验码），这也是编码理论研究的主题之一。





英语的熵

- 香农特别对测量英语的熵感兴趣，将其表示为一系列的字母。这意味着我们想象存在一个“真实”的分布 p （这种存在是有问题的，但它仍然是一个有用的数学抽象），它能产生英语文本样本 $x \sim p$ 。

- 香农还定义了交叉熵：

$$H(p, q) = - \sum_x p(x) \log q(x)$$

- 这测量了需要多少比特（nats）来编码样本 $x \sim p$ ，使用由模型 q 给出的压缩方案（用长度为 $1/q(x)$ 的代码表示 x ）。
- 通过语言模型估计熵。一个关键的属性是，交叉熵 $H(p, q)$ 上界是熵 $H(p)$ 。
- 这意味着我们可以通过构建一个只有来自真实数据分布 p 的样本的（语言）模型 q 来估计 $H(p, q)$ ，而 $H(p)$ 通常无法访问，如果 p 是英语的话。



英语的熵

- 所以我们可以构建更好的模型 q 来得到熵 $H(p)$ 的更好的估计，由 $H(p, q)$ 衡量。
- 香农游戏（人类语言模型）。香农首先在1948年使用 n -gram模型作为 q ，但在他1951年的论文《打印英语的预测和熵》中，他引入了一个巧妙的方案（称为香农游戏），其中 q 是由人提供的：
 - "the mouse ate my ho_"
- 人们不擅长提供任意文本的校准概率，所以在香农游戏中，人类语言模型会反复尝试猜测下一个字母，然后我们会记录猜测的次数。





④ 用于下游应用的N-gram模型

④ 语言模型首先被用于需要**生成文本**的实践应用：

- 1970年代的语音识别（输入：声音信号，输出：文本）
- 1990年代的机器翻译（输入：源语言的文本，输出：目标语言的文本）

④ **噪声信道模型**。当时解决这些任务的主要模型是噪声信道模型。以语音识别为例：

- 我们假设有一些从某个分布 p 中抽取的文本
- 这些文本被转换为语音（声音信号）
- 然后给定语音，我们希望恢复（最有可能的）文本。这可以通过贝叶斯定理实现：

$$p(\text{text} \mid \text{speech}) \propto \underbrace{p(\text{text})}_{\text{language model}} \underbrace{p(\text{speech} \mid \text{text})}_{\text{acoustic model}}.$$

- 语音识别和机器翻译系统使用了基于词的n-gram语言模型（最早由香农引入，但针对的是字符）。



④ 用于下游应用的N-gram模型

- ④ 在一个n-gram模型中，关于 x_i 的预测只依赖于最后的 $n-1$ 个字符 $x_{i-(n-1):i-1}$ ，而不是整个历史：

$$p(x_i | x_{1:i-1}) = p(x_i | x_{i-(n-1):i-1})$$

- ④ 例如，一个trigram ($n=3$) 模型会定义：

- $p(\text{cheese} | \text{the, mouse, ate, the}) = p(\text{cheese} | \text{ate, the})$ 。

- ④ 这些概率是基于各种n-gram（例如，ate the mouse 和ate the cheese）在大量文本中出现的次数计算的，并且适当地平滑以避免过拟合（例如，Kneser-Ney平滑）。





④ 用于下游应用的N-gram模型

- ④ 将n-gram模型拟合到数据上非常便宜且可扩展。因此，n-gram模型被训练在大量的文本上。例如，[Brants等人 \(2007\)](#)在**2万亿个tokens上训练了一个5-gram模型用于机器翻译**。相比之下，GPT-3只在3000亿个tokens上进行了训练。然而，n-gram模型有其根本的限制。想象以下的前缀：

- **Stanford has a new course on large language models. It will be taught by ____**

- ④ 如果n太小，那么模型将无法捕获长距离的依赖关系，下一个词将无法依赖于Stanford。然而，如果n太大，统计上将无法得到概率的好估计（即使在“大”语料库中，几乎所有合理的长序列都出现0次）：

- **count(Stanford,has,a,new,course,on,large,language,model)=0。**

- ④ 因此，语言模型被限制在如语音识别和机器翻译等任务中，其中声音信号或源文本提供了足够的信息，只捕获局部依赖关系（而无法捕获长距离依赖关系）并不是一个大问题。





④ 神经语言模型

④ 语言模型的一个重要进步是**神经网络的引入**。[Bengio等人](#)在2003年首次提出了神经语言模型，其中 $p(x_{\{i\}} | x_{\{i-(n-1):i-1\}})$ 由神经网络给出：

- $p(\text{cheese} | \text{ate, the}) = \text{some-neural-network}(\text{ate, the, cheese})$.

④ 自2003年以来，神经语言建模的**两个关键发展**包括：


- **Recurrent Neural Networks (RNNs)**，包括长短期记忆 (LSTMs)，使得一个词元 x_i 的条件分布可以依赖于整个上下文 $x_{\{1:i-1\}}$ （有效地使 $n=\infty$ ），但这些模型难以训练。
- **Transformer** 是一个较新的架构（于2017年为机器翻译开发），再次返回固定上下文长度 n ，但更易于训练（并利用了GPU的并行性）。此外， n 可以对许多应用程序“足够大”（GPT-3 使用的是 $n=2048$ ）。






人工智能的发展

- ① 人工智能技术经历了小数据到大数据，小模型到大模型，专用到通用的发展历程，正逐步进入**大模型时代**
- ② 在海量无标注数据上进行**大规模自监督预训练**，学习到大量的语言知识与世界知识
- ③ 通过**自然语言交互**完成多种任务，具备了多场景、多用途、跨学科的任务处理能力



大模型的范畴






预训练语言模型

语言智能新范式—预训练语言模型（代表：ELMo、BERT、GPT-1/2）

- 大规模数据上**自监督预训练**，经**微调**后适配各类任务，有效利用**大数据**、**大模型**和**大算力**
- 主要应用于语言解析和理解任务






主要类型

各类模型的关注度随时间变化

- 约2021年之前，编码器模型和编解码模型的衍生版不断出现。各版本被趣称为“BERTology”
- 约2021年之后，解码器模型得到飞速的发展，迎来了“Next_x0002_Level”的生成式大模型时代

- 编码器模型 (Encoder-Only)
- 解码器模型 (Decoder-Only)
- 编解码模型 (Encoder-Decoder)




[1] Rogers, Anna, et al. A primer in BERTology: What we know about how BERT works. TACL, 2021.

[2] Minaee, Shervin, et al. Large language models: A survey. arXiv preprint arXiv:2402.06196


从预训练建模的视角

从自监督预训练建模的角度，不同架构的训练目标存在差异


- **编码器模型**：掩码语言建模 (Masked Language Modeling)
- **解码器模型**：自回归语言建模 (Auto-regressive Language Modeling)
- **编解码模型**：序列到序列建模 (Sequence to Sequence Modeling)



$$\mathcal{L}_{\text{MLM}} = - \sum_{x_m \in M(\mathbf{x})} \log \mathbf{P}(x_m | \mathbf{x}_{\setminus M(\mathbf{x})})$$



$$\mathcal{L}_{\text{LM}} = - \log \mathbf{P}(\mathbf{x}) = - \sum_{i=1}^T \log \mathbf{P}(x_i | x_{<i})$$



$$\mathcal{L}_{\text{Seq2Seq MLM}} = - \sum_{\mathbf{x}_{i:j} \in M(\mathbf{x})} \sum_{t=i}^j \log \mathbf{P}(x_t | \mathbf{x}_{\setminus M(\mathbf{x})}, \mathbf{x}_{i:t-1})$$




编码器模型

④ **主要训练目标：**掩码语言建模 (Masked Language Modeling, MLM)

$$\mathcal{L}_{\text{MLM}} = - \sum_{x_m \in M(\mathbf{x})} \log \mathbf{P}(x_m | \mathbf{x} \setminus M(x))$$

④ **代表性的模型：**BERT、RoBERTa、ALBERT



NotNext

学习

Transformer Encoder

[CLS]

让

我们

一起

动手

[MASK]

大模型

开发

全流程





解码器模型

① **主要训练目标：自回归语言建模 (Auto-regressive Language Modeling)**

$$\mathcal{L}_{\text{LM}} = -\log \mathbf{P}(\mathbf{x}) = -\sum_{i=1}^T \log \mathbf{P}(x_i | x_{<i})$$


② **代表性的模型：GPT、Llama、PaLM等系列**





优缺点对比

编码器模型 (BERT)




优点: 利用双向上下文，语言理解效果好

缺点:

使用[mask]特殊符号，导致预训练-微调差异；假设所有被mask的token相互独立

解码器模型 (GPT)



优点: 天然适合生成类任务，容易构造大规模的训练数据

缺点:

局限于单向建模，难以同时利用双向上下文信息







编解码模型

主要训练目标：序列到序列建模 (Sequence to Sequence Modeling)

$$\mathcal{L}_{\text{Seq2Seq MLM}} = - \sum_{\mathbf{x}_{i:j} \in M(\mathbf{x})} \sum_{t=i}^j \log \mathbf{P}(x_t | \mathbf{x} \setminus M(\mathbf{x}), \mathbf{x}_{i:t-1})$$


代表性的模型：T5、BART






针对应用场景的模型选择

编码器模型




分类回归等判别式任务

解码器模型



适合开放生成任务

编解码模型




兼具判别与生成能力

03

Basic Concepts

LLMs





在本次课程中，我们将简单看看**GPT-3**——这个具有代表性的大型语言模型的能力，主要基于**GPT-3论文**中的基准测试。

实验的任务选择如下：

- Language modeling
- Question answering
- Translation
- ...



1、Language Modeling

- 困惑度 (Perplexity) 是一个重要的指标，是自然语言处理和语言模型中的一个重要概念，用于衡量语言模型的性能。它可以解释为模型在预测下一个词时的平均不确定性。简单来说，如果一个模型的困惑度较低，那么它在预测下一个词的时候就会更加准确。对于给定的语言模型和一个测试数据集，困惑度被定义为：

$$P(X) = P(x_1, x_2, \dots, x_N)^{(-1/N)}$$

- 其中， $X=x_{\{1\}}, x_{\{2\}}, \dots, x_{\{N\}}$ 是测试集中的词序列， N 是测试集中的总词数。困惑度与语言模型的质量紧密相关。一个优秀的语言模型应能准确预测测试数据中的词序列，因此它的困惑度应较低。相反，如果语言模型经常做出错误的预测，那么它的困惑度将较高。



1、Language Modeling

- **Penn Tree Bank** 是自然语言处理中的一个经典数据集，最初是为了进行句法解析而标注的。从Emami和Jelinek (2004) 和Mikolov和Zweig (2012) 开始，一个**只包含华尔街日报文章的版本**被用作语言模型评估。需要注意的是，若对PTB数据集使用语言模型对其基准进行测试，需要原始数据集做一些重要预处理，比如数据格式转换。
- **适应性测试**。将整个文本作为提示输入到GPT-3中，并评估其困惑度（示例）：
 - *Pierre Vinken, 61 years old, will join the board as a nonexecutive director Nov. 29. Mr. Vinken is chairman of Elsevier N.V., the Dutch publishing group.*
- **结果**：GPT-3大幅度的超过了当时的最好结果。

Model	Perplexity
GPT-3	20.5
BERT-Large-CAs1	31.3





② Question answering

- 现在考虑（闭卷）问答题，其中输入是一个问题，输出是一个答案。语言模型必须以某种方式“知道”答案，而无需在数据库或一组文档中查找信息。
 - *Input: What school did burne hogarth establish?*
 - *Output: School of Visual Art*
- TriviaQA
 - 任务：给定一问题后生成答案
 - 原始数据集是由**业余爱好者收集的，并被用作开放式阅读理解的挑战**，但我们用它来进行（闭卷）问题回答。我们根据训练实例和问题定义一个提示，并将完成的内容作为预测的答案
 - *Q: 'Nude Descending A Staircase' is perhaps the most famous painting by which 20th century artist?*
 - *A: Marcel Duchamp*




大模型的能力

2、Question answering

- 结果:

Model	Accuracy
RAG	68.0
GPT-3(zero-shot)	64.3
GPT-3(few-shot)	71.2

- 我们也看到，增加模型大小和增加in-context training实例都有助于提高性能。





3、Translation

- **翻译任务**是将**源语言**（例如，德语）中的句子翻译成**目标语言**（例如，英语）中的句子。
- 由于存在多种可能的翻译，所以（自动）**评估指标是BLEU**（它捕获了n-gram重叠的概念）。对于Few-shot的情况，我们构造了一个包含输入-输出训练实例以及输入的提示
 - *Mein Haus liegt auf dem Hügel. = My house is on the hill.*
 - *Keinesfalls dürfen diese für den kommerziellen Gebrauch verwendet werden. = In no case may they be used for commercial purposes.*
- **结果(从德语到英语):**


Model	Accuracy
GPT-3(zero-shot)	27.2
GPT-3(few-shot)	40.6



04


Types

LLMs





大模型的能力版图







从GPT-3到ChatGPT

- 🕒 **GPT-1**: 单向自回归建模 + 有监督微调, 探索“预训练+微调”范式下的自然语言任务求解能力
- 🕒 **GPT-2**: 单向自回归建模 + 更多的数据、更大的模型, 探索基于自然语言提示的多任务解决能力
- 🕒 **GPT-3**: 探索了千亿参数规模的语言模型效果, 提出了基于“上下文学习”的任务解决方法
- 🕒 **GPT-3.5/ChatGPT**: 指令微调 + 人类反馈 + 对话优化
- 🕒 **GPT-4**: 多模态能力, 更长的上下文理解与处理能力, 更高效的训练与预测, 更广泛的高价值应用场景

景




GPT 系列演进





GPT系列的版本演化

- ④ GPT-4在各种专业和学术基准上表现出人类相当的水平，包括约前 10% 的成绩通过模拟律师资格考试
- ④ 强大的多模态处理能力扩大了 GPT-4 的应用范围，同时生成式的幻觉、安全问题均有较大的改善



OpenAI 发布 GPT-4 使用指南

- 写出清晰的指令
- 提供参考文本
- 将复杂的任务拆分为更简单的子任务
- 给模型时间「思考」
- 使用外部工具
- 系统地测试变更



[1] Achiam, Josh, et al. Gpt-4 technical report. arXiv preprint arXiv:2303.08774.

[2] OpenAI. Prompt engineering. <https://platform.openai.com/docs/guides/prompt-engineering>.



Llama系列大模型

- 🔴 开源自回归模型，基于Transformer架构，参数规模从 7B到 405B 不等
- 🔴 商用许可：Llama 1不可免费商用， Llama 2和Llama 3可商用（需申请商用许可）

版本特点	Llama-1	Llama-2	Llama-3	Llama-3.1	Llama-3.2
模型规模	7B-65B	7B-70B	8B-70B	8B-405B	1B-90B
数据规模	1.4T	2T	15T	15T	9T
多模态	×	×	×	×	√
多语言	×	×	×	√	√
工具调用	×	×	×	√	√
训练范式	预训练	预训练+指令微调+RLHF	预训练+指令微调+DPO	预训练+指令微调+DPO	预训练+指令微调+DPO
上下文长度	2K	4k	8k	131K	131K
主要演变	--	增加后训练	扩展预训练	1. 增加模型规模 2. 增加多语言和工具能力 3. 扩展上下文长度	1. 增加端侧模型 2. 增加多模态能力

[1] Touvron, Hugo, et al. Llama: Open and efficient foundation language models. arXiv preprint arXiv:2302.13971.
[2] Touvron, Hugo, et al. Llama 2: Open foundation and fine-tuned chat models. arXiv preprint arXiv:2307.09288.
[3] Dubey, Abhimanyu, et al. The llama 3 herd of models. arXiv preprint arXiv:2407.21783





Llama系列大模型

🔴 训练数据: CommonCrawl, C4, Github, Wikipedia, books, ArXiv, and StackExchange等

🔴 开源地址: <https://github.com/facebookresearch/llama>

🔴 Llama 3.1 405B 在广泛评测中超越 GPT-3.5 Turbo、大部分基准测试得分超过了 GPT-4 0125

Category Benchmark	Llama 3.1 405B	Nemotron 4 340B Instruct	GPT-4 0125	GPT-4 Omni	Claude 3.5 Sonnet
General					
MMLU (0-shot, CoT)	88.6	78.7 (non-CoT)	85.4	88.7	88.3
MMLU PRO (5-shot, CoT)	73.3	62.7	64.8	74.0	77.0
IFEval	88.6	85.1	84.3	85.6	88.0
Code					
HumanEval (0-shot)	89.0	73.2	86.6	90.2	92.0
MBPP EvalPlus (base) (0-shot)	88.6	72.8	83.6	87.8	90.5
Math					
GSM8K (8-shot, CoT)	96.8	92.3 (0-shot)	94.2	96.1	96.4 (0-shot)
MATH (0-shot, CoT)	73.8	41.1	64.5	76.6	71.1
Reasoning					
ARC Challenge (0-shot)	96.9	94.6	96.4	96.7	96.7
GPQA (0-shot, CoT)	51.1	-	41.4	53.6	59.4
Tool use					
BFCL	88.5	86.5	88.3	80.5	90.2
Nexus	58.7	-	50.3	56.1	45.7
Long context					
ZeroSCROLLS/QuALITY	95.2	-	95.2	90.5	90.5
InfiniteBench/En.MC	83.4	-	72.1	82.5	-
NIH/Multi-needle	98.1	-	100.0	100.0	90.8
Multilingual					
Multilingual MGSM (0-shot)	91.6	-	85.9	90.5	91.6

Category Benchmark	Llama 3.1 8B	Gemma 2 9B IT	Mistral 7B Instruct	Llama 3.1 70B	Mixtral 8x22B Instruct	GPT 3.5 Turbo
General						
MMLU (0-shot, CoT)	73.0	72.3 (5-shot, non-CoT)	60.5	86.0	79.9	69.8
MMLU PRO (5-shot, CoT)	48.3	-	36.9	66.4	56.3	49.2
IFEval	80.4	73.6	57.6	87.5	72.7	69.9
Code						
HumanEval (0-shot)	72.6	54.3	40.2	80.5	75.6	68.0
MBPP EvalPlus (base) (0-shot)	72.8	71.7	49.5	86.0	78.6	82.0
Math						
GSM8K (8-shot, CoT)	84.5	76.7	53.2	95.1	88.2	81.6
MATH (0-shot, CoT)	51.9	44.3	13.0	68.0	54.1	43.1
Reasoning						
ARC Challenge (0-shot)	83.4	87.6	74.2	94.8	88.7	83.7
GPQA (0-shot, CoT)	32.8	-	28.8	46.7	33.3	30.8
Tool use						
BFCL	76.1	-	60.4	84.8	-	85.9
Nexus	38.5	30.0	24.7	56.7	48.5	37.2
Long context						
ZeroSCROLLS/QuALITY	81.0	-	-	90.5	-	-
InfiniteBench/En.MC	65.1	-	-	78.2	-	-
NIH/Multi-needle	98.8	-	-	97.5	-	-
Multilingual						
Multilingual MGSM (0-shot)	68.9	53.2	29.9	86.9	71.1	51.4



国产AI大模型分类及典型案例

百模大战：据不完全统计，截至2024年4月底，国内共推出305个大模型



通用大模型	闭源	文心一言 讯飞星火 通义千问 vivo BlueLM oppo AndesGPT 商汤日日新 sensenova 出门问问 序列猴子 天工 字节云雀大模型 腾讯混元 Scitrain 西湖心辰 西湖大模型 Moonshot AI 言犀 360智脑 盘古大模型 MiLM-6B 云从科技 云从科技从容大模型 深言科技 DeepLang AI MINIMAX 云知声 山鹰 4Paradigm SageGPT 澜舟科技 孟子 intellifusion 云天书 AISPEECH DFM 玉言 AiLMe											
		百川Baichuan ChatGLM2-6B Qwen-7B Yi Yi-34B XVERSE 元象 InternLM ChatYuan Fengshenbang-LM CPM-Bee OpenBuddy MOSS TigerBot RWKV-LM Firefly 中文LLaMA & Alpaca大模型 2 FlagAI											
行业大模型	部分领域	医疗						汽车					
		医联 / MedGPT 大德中医 岐黄问道 DISC-MedLLM						理想 MindGPT DriveGPT 广汽AI大模型					
		教育						金融					
		MathGPT 作业帮 银河大模型 子曰						蚂蚁金融大模型 轩辕大模型 度小满					
		工业						文化/零售/交通					
		AlInno-15B COSMO-Plot COSMO-GPT SmartMore SMore LrMo						阅文集团 妙笔大模型 晓模型 XPT 乐言科技 PCI佳都科技					



Qwen系列大模型

① **通义千问 (Qwen)** 是阿里云研发的预训练语言模型，执行理解、生成和解释人类语言、图片和文档等任务，在创意文案、办公助理、学习助手、趣味生活等方面为用户提供丰富的交互体验

② 具备中英文理解、数学推理、代码理解等能力



[1] Bai, Jinze, et al. Qwen technical report. arXiv preprint arXiv:2309.16609.

[2] Yang, An, et al. Qwen2 technical report. arXiv preprint arXiv:2407.10671.



Qwen系列的版本演化

- 🌀 Qwen1.5: Model Scaling向更大和更小扩展、MoE、AWQ/GGUF
- 🌀 Qwen2: 多语言增强、长文本能力增强
- 🌀 Qwen2.5: 数学、代码能力增强、多语言增强
- 🌀 Scaling
 - Qwen: 1.8B, 7B, 14B, and 72B models
 - Qwen1.5: 0.5B, 1.8B, 4B, 14BA2.7B, 7B, 14B, 32B, 72B, and 110B models
 - Qwen2: 0.5B, 1.5B, 7B, 57A14B, and 72B models
 - Qwen2.5: 0.5B, 1.5B, 3B, 7B, 14B, 32B, and 72B models

版本迭代特点

- 结构优化 (MoE提高训练效率)
- 预训练数据的数量扩充与质量提升
- 丰富Post-training阶段涵盖任务和领域
- 窗口长度的扩展 (训练数据和训练策略两方面)
- 多语言语向扩增与能力增强
- 专项能力增强 (训练专家模型+以专家模型带动基模)
- 模态扩展 (Qwen-VL、Qwen-Audio)





1

2023.11

DeepSeek LLM

参数规模：70B、67B参数

架构：Dense（稠密）Transformer 模型

训练数据：2T token中英文语料

训练范式：遵循预训练+SFT+DPO标准大模型训练范式

性能：DeepSeek的首个大模型，对标Llama2系列。67B Base版本在推理、编码等方面超越了Llama2 70B Base。模型架构采用Dense结构

2

2024.5

DeepSeek-V2

参数规模：236B参数，激活参数21B

架构：引入DeepSeekMoE（混合专家）架构。引入MLA（Multi-head Latent Attention）

训练数据：8.1T token语料

训练范式：遵循预训练+SFT+强化学习标准范式

特点：性能比肩GPT-4 Turbo。MLA使得KV cache节约90%以上，推理速度提升5倍以上。MoE架构使得模型参数扩大时，推理成本几乎不变，训练成本大幅降低，提升模型能力



3

2024.9

DeepSeek-V2.5

基于V2，主要优化了通用任务能力和代码能力

4

2024.12

DeepSeek-V3

参数规模：671B参数，激活参数37B

训练数据：14.8T token语料

架构：在V2基础上，引入Auxiliary-loss-free strategy来进行专家均衡。引入Multi-Token Prediction training提升模型性能和加速推理。引入FP8混合精度降低训练和推理开销

训练数据：14.8T token语料

训练范式：遵循预训练+SFT+DPO标准大模型训练范式

特点：性能超越主流的Llama3系列和Qwen2.5系列，且训练开销和推理开销大幅降低





4

2024.12

DeepSeek-V3

参数规模：671B参数，激活参数37B

训练数据：14.8T token语料

架构：在V2基础上，引入Auxiliary-loss-free strategy来进行专家均衡。引入Multi-Token Prediction training提升模型性能和加速推理。引入FP8混合精度降低训练和推理开销

训练数据：14.8T token语料

训练范式：遵循预训练+SFT+DPO标准大模型训练范式

特点：性能超越主流的Llama3系列和Qwen2.5系列，且训练开销和推理开销大幅降低

5

2025.01

DeepSeek-R1

基座模型：DeepSeek-V3-Base

训练数据：14.8T token语料


训练范式：在base模型上直接进行多阶段训练、冷启动训练和强化学习

特点：首次达到了类GPT4-O1的推理能力



05

Acknowledge





④ 该部分课件主要参考网上现有资料以及现有开源项目：

- <https://github.com/datawhalechina/so-large-lm>
- <https://github.com/yunwei37/Prompt-Engineering-Guide-zh-CN>
- <https://github.com/Lordog/dive-into-llms>



谢谢！

饮水思源 爱国荣校