



上海大学
Shanghai University

大模型与金融

基本概念和工具

高洪皓

计算机学院



第I部分： AI时代的金融变革起点

金融行业的智能转型

➤ 讨论：你觉得AI能帮金融做什么？

图：金融科技及金融大模型市场快速增长



资料来源：艾瑞咨询，沙利文，国信证券经济研究所整理

从传统模型到“大模型”，AI技术在金融变革中是核心环节

可以风控建模、客户服务、投资分析、反洗钱监测.....

什么是大模型

- **定义：**大语言模型 (LLM, Large Language Model) 是一类通过大规模语料训练的神经网络，具备自然语言理解与生成能力。

预训练 (Pretraining) :
先让模型 “读遍互联网”，
掌握通用语言规律。



微调 (Finetuning) :
在特定金融任务上 “专门训练”。


对齐 (Alignment) :
通过人类反馈或规则让它说 “人话”，更符合预期。

什么是大模型

➤ 讨论：大语言模型为什么强？

参数多 ≠ 智商高，大模型厉害在哪？

- 大模型学的是“**语言概率**”，非逻辑推理，而是压缩人类写过的文字规律。
- 它不是在“理解”，而是在“**拟合语言规律**”



不同模型参数对比图

什么是大模型

01

大模型通过语言规律压缩世界知识，具备**自动总结**年报、识别政策倾向等能力，但并非真正理解，而是语言概率建模。

泛化能力

02

大模型参数规模庞大，如GPT-4达17600亿，但能力不仅依赖参数，更在于**泛化能力**和专业知识的结合。

参数与能力

03

金融语言抽象且合规要求高，大模型**通过新闻、年报等数据训练**，如FinGPT和BloombergGPT，实现专业金融任务处理。

金融语言建模



什么是大模型

➤ 金融术语 = 抽象 + 合规 + 模糊

语言表达比表

金融术语表达	普通语言表达
2023年宏观层面存在内生性增长乏力，货币政策维持边际宽松，企业信贷需求结构性分化。	2023年经济整体偏弱，贷款不太好批，很多企业也不太想借钱。
居民部门呈现主动去杠杆趋势，按揭需求持续走低，消费金融同比负增长。	大家都不太愿意贷款买房或消费，更多人选择把钱存起来。
地方政府隐性债务问题导致基建融资受限，信贷投放结构需进一步优化。	一些地方政府负债太多，导致基础建设的钱不好借。
金融机构风险偏好下行，信贷扩张节奏趋于谨慎。	银行现在放贷变得更保守了，审批比以前更慢更严了。

金融语言难点：

- 概念抽象：“中性偏鸽” “逆周期工具”
 - 合规术语：“非公开信息” “穿透监管”
- 表达模糊、含义深
 - 语境依赖强，逻辑链复杂

什么是大模型

金融语言特点

01

金融语言具有高度抽象性、合规性和专业性，涉及术语如“内生性风险”“定价信号”等，需通过专业数据训练模型以准确理解。

训练数据来源

02

大模型训练数据包括新闻、年报、宏观数据解读报告、投资研报、社交舆情及客户服务问答数据，确保模型掌握金融语言与知识。

数据经过清洗、标注、训练/再训练

模型选择

03


如FinGPT专注于财经研报、公告和行情文本，提供精准的金融信息分析与生成。如BloombergGPT结合通用与专业数据，适用于复杂金融场景。



第II部分： 大模型落地核心金融场景


1. 客户服务与金融问答

传统客服系统的痛点



- 规则匹配死板
- 无法理解上下文
- 回复模板单一



大模型客服的优势



- 上下文理解
- 多轮对话记忆
- 任务导向
- 安全控制

案例：江苏银行利用大模型提高智能客服应答准确率

- **背景：**传统客服机器人依赖规则库，对复杂问题（如理财产品对比、贷款政策解读）应答准确率不足
- **技术路径：**
 - **向量检索与匹配：**首先运用智慧小苏 L1 模型**对用户提问进行向量检索**，其次在知识库中匹配到的向量检索内容**形成对 L2 模型的提示工程**。
 - **微调训练与反馈：**L2 模型在该场景经过微调训练后，**能够将知识反馈融入到提示工程中**，通过 L2 模型进行反馈和输出。




2. 风险管理与合规监控

传统做法的局限



- 风控模型多依赖结构化数据
(KPI指标、财报数字)
- 合规审查依赖人工逐条查阅文件，效率低、主观性强


大模型带来的突破



- 非结构化文本理解能力
- 语义层面的“模糊匹配”能力
- 多任务风险识别框架(尤其并发)

案例：花旗银行用大模型识别“隐性合规风险”

- **背景：**传统审查依赖人工阅读监管文档 + 检查客户资料，效率低 & 有遗漏
- **大模型做了什么？**
 - 让模型“读”数万页合规规则、历史违规案例
 - 自动比对当前客户行为与历史风险模式
 - 提示“可能违规”或“应补充披露”的条款
- **成效：**
 - 审核时间缩短60%+
 - 发现多起“人工审查未标记”的潜在问题
 - 有效支撑后续监管响应策略




3. 投资研究与智能分析

传统投资研究的难点



- 信息过载：每天有成千上万篇研报、公告、新闻
- 人工筛选成本高，信息覆盖面受限
- 投资建议高度依赖分析师主观判断

大模型如何生成投资建议



- 通过训练学会“公司基本面 + 市场情绪 + 行业趋势”的综合判断逻辑
- 可依据投资者“风险偏好 + 偏好行业 + 时间周期”自动组合资产配置建议

案例：研报生成

- 用大模型生成的研报，可自动完成信息检索、财务数据提取与要点分析，提升投资研究的效率与覆盖面。
- 相较于人工处理，能在数分钟内生成结构清晰、逻辑完整的研报初稿，辅助分析师快速做出判断。

分析拼多多2024年年度财报和2024年Q4的财报

小白研报

最多需要20分钟，进行深度研究、分析和反思，并生成完整报告和网页。

我将深入研究拼多多2024年全年及第四季度的财务报表，重点关注其营收结构、利润变化、成本控制和现金流状况，并结合市场环境和行业趋势，评估其经营策略的有效性和未来发展潜力。

我已明确拼多多2024年年度财报和Q4财报的分析方向，需从财务数据、战略转型及行业背景三方面入手。官方财报是获取权威数据的基础，行业解读和竞争对手对比则提供补充视角。
我将优先搜索拼多多2024年年度财报和Q4财报的官方文件，以确保数据的准确性和完整性，为后续分析奠定基础。

我正在搜索网页 ^

Q 拼多多 2024 年度财报 2024 Q4 财报 官方

为您检索到30篇内容

我已获取拼多多2024年全年及Q4财报的核心数据，包括营收增长、净利润变化及研发投入等初步信息。这些数据为分析其财务表现提供了基础。
我将阅读相关内容，重点了解收入结构、用户指标及战略转型成效，以支持对财报细节的深入理解。

我开始浏览网页 ^

🔗 拼多多年报图解：营收3938亿，增速放缓 加码生态投入 雷递 ...

🔗 拼多多财报背后：新质商家初长成|拼多多|财报|人民币_新浪 ...

🔗 拼多多高管解读Q4财报：接下来依旧会在消费端坚持长期 ...

🔗 拼多多发布2024四季度及全年财报，陈磊：坚持高质量发展 ...

我已掌握拼多多2024年全年及Q4财报的关键数据，包括营收增长、毛利率变化及战略转型举措等。这些信息为分析其财务表现和竞争优势提供了重要基础。

我将搜索拼多多2024年的用户指标数据，以评估其用户增长趋势及消费行为变化，为后续分析提供更全面的视角。

我正在搜索网页 ^

Q 拼多多 2024 MAI 用户指标 财报

拼多多2024年财报分析

高质量发展战略下的转型与挑战

营收增长
59%

净利润增长
87%

运营利润率
23%

现金储备
3316亿

财报概览

2025年3月20日，拼多多发布年度财报，展现了其在复杂经济环境中的强劲表现，标志着其高质量发展战略进入关键收获期。公司全年营收达到3938亿元，较上年同期增长59%；全年净利润达到1124亿元，较上年同期大幅增长87%。

4. 量化交易

什么是量化交易？



- 量化交易是一种通过数学模型和算法程序，基于海量历史与实时数据进行证券买卖决策的方式

大模型做量化的独特优势



- 非结构化数据分析
- 趋势语言建模
- 语义驱动策略生成
- 跨市场/多因子理解



第III部分： 数据融合与模型演进

金融数据遇上大模型

非结构化数据价值爆发



01

金融数据构成现状分析： 公司年报平均长度超过
金融机构80%数据为非结构化




02

典型非结构化数据类型： 公司年报平均长度超过
150页，电话会议日均
产生2.5万小时录音



03

传统NLP技术痛点：
基于BERT的模型在财报情绪分析任务中F1
值仅68%



04

大模型突破性表现：
在财报摘要任务中，
大模型准确率有明显
提高

金融数据遇上大模型

多模态金融AI: Beyond文本



应用场景：结合
商品价格预测股
价波动



案例研究：挖掘跨
模态因子，实现年
化超额收益提升



GraphRAG技术架
构解析：知识图谱
+ 向量数据库
的融合存储机制



实时联合分析系统：
行情数据流与研报
语义分析的动态耦
合模型



金融机构专属模型发展

01 参数演进趋势

BloombergGPT: 500亿参数，专注于金融领域，提升对金融文本的理解和生成能力。

03 知识蒸馏实践


中信证券将700亿参数模型压缩至130亿，推理速度提升5倍，F1值保持91%

02 关键技术突破

LoRA微调技术通过低秩分解优化训练过程，显著降低训练成本。

04 检查模块合规

确保模型输出符合金融监管要求，审计追踪功能满足SEC要求。





第IV部分

挑战、趋势

挑战与风险



未来趋势

金融服务普惠化和智能化

AI成为金融从业者的“标配工具”

01

随着AI技术的不断成熟，金融大模型将具备更强的认知能力和推理能力，成为金融从业者的必备工具

技术融合与创新

02

AI将与区块链、知识图谱等新兴技术深度融合，形成更强大的金融科技解决方案

03

通过AI技术，金融机构能够降低运营成本，提高服务效率，为更广泛的客户群体提供便捷、高效的金融服务

如何准备



了解Python等编程语言，但无需成为专业程序员。掌握这些基础技能可以帮助你更好地理解和应用AI工具



学会与AI高效对话，如掌握prompt工程能力，能够更精准地指导AI完成任务



关注金融与数据科学、行为经济学与AI的交叉领域。具备跨学科背景的金融专业人才将更具竞争力



第V部分： Deepseek及本地化部署

DeepSeek来了，它是谁？



浙江大学学子

❖ DeepSeek全称

- 杭州**深度求索 (DeepSeek)** 人工智能基础技术研究**有限公司**，创始人：**梁文锋**
- 幻方量化基金，2023年7月17日成立，专注开发大模型及相关技术

❖ DeepSeek——**高性能、低成本的国产开源大模型**



❖ DeepSeek大模型产品

- DeepSeek-Math
- DeepSeek-Coder
- DeepSeek-Math
- DeepSeek-VL、VL2
- DeepSeek-V2、V2.5
- **DeepSeek-V3**
- **DeepSeek-R1**
- **DeepSeek-R1-Zero**
- ...


DeepSeek是什么



deepseek

高性能、低成本的、**国产开源大模型!**

- DeepSeek-R1发布开源，擅长处理复杂且在训练阶段大规模使用了强化学习技术，在仅有极少标注数据的情况下，极大提升模型推理能力。
- DeepSeek-R1在数学、代码、自然语言推理等任务上，性能比肩OpenAI o1正式版。
- 目前大模型主流榜单开源模型DeepSeek-V3位列榜首，与世界上最先进的闭源模型不分伯仲。



DeepSeek多场景全面接入


三大基础运营商、超过15家芯片厂家、200多家企业（涉及云服务、网络科技、金融等领域）、多个手机厂商和车企，以及地方政府政务系统等。

❖ 世界级的云计算巨头：微软、英伟达、亚马逊宣布接入DeepSeek。

❖ DeepSeek的“朋友圈”瞬间扩大，引领大模型在AI领域的创新应用

DeepSeek的“朋友圈”

已采用或接入DeepSeek的国内企业/品牌/产品/服务，持续更新中...




金融：国泰君安、兴业证券、华安证券、广发证券、中泰证券、华福证券、国金证券、国元证券、国信证券、华西证券、东兴证券、西南证券、光大证券、国盛证券、中金财富证券、中建投证券、江苏银行、邮储银行、北京银行、重庆银行、苏商银行、海安农商银行、乐信、汇添富、富国基金、诺安基金、新华保险、中国平安

运营商：中国移动、中国电信、中国联通

公众号 · 新智元

什么是DeepSeek的本地化部署

❖ DeepSeek的本地化部署是指将人工智能系统（如模型、算法及服务）部署在用户指定的本地服务器或基础设施中，而非依赖云端服务，旨在实现数据主权掌控、文化适配优化和合规性保障的技术方案。其核心是通过技术与场景的深度结合，满足特定区域、行业或机构的个性化需求。



本地化部署的优点

1. 数据隐私安全

- **敏感数据保护**：数据无需上传至第三方云端，避免传输和存储过程中的泄露风险，适合医疗、金融、政府等敏感领域。
- **完全控制**：企业自主管理数据访问权限，降低外部攻击或内部滥用风险。
- **符合安全审计**：本地环境更容易满足严格的安全审计要求（如ISO 27001）。

2. 法律合规性

- **数据主权**：满足GDPR、HIPAA等法规对数据存储位置的要求（如数据不得跨境传输）。
- **规避监管风险**：金融、医疗等行业的本地部署数据管理通常符合行业法规要求，避免法律纠纷。

3. 性能优化与低延迟

- **实时响应**：本地处理消除网络延迟，提升高频交互场景（如客服、实时翻译）的体验。
- **资源独占**：硬件资源专用于模型推理，避免云服务多租户环境下的资源争抢。

4. 高度定制化

- **模型微调**：可根据企业垂直领域（如法律、医疗）调整模型参数，提升专业场景的准确性。
- **系统集成**：灵活对接内部数据库、ERP等系统，实现个性化功能。
- **版本控制**：自由选择或回滚模型版本，避免云服务强制更新导致的兼容性问题。

5. 长期成本效益

- **减少云服务依赖**：避免持续支付API调用费用，尤其在高频使用场景下成本优势显著。
- **硬件自主规划**：可按需选择服务器配置，平衡性能与预算，长期摊销硬件投入。

6. 稳定性和可靠性

- **规避云服务风险**：不受供应商服务中断、API限制或政策变动影响，保障业务连续性。
- **灾备可控**：可自主设计备份和容灾方案，提升系统鲁棒性。

7. 技术自主性

- **避免供应商锁定**：掌握核心技术栈，减少对第三方平台的依赖，保障长期战略灵活性。
- **知识产权保护**：模型与数据的本地化管控降低知识产权外流风险。

缺点：成本高

DeepSeek的连接官网简单使用

❖ 连接官网

- <https://chat.deepseek.com>
- 首次使用注册一个账户
 - 手机号或邮箱地址



The image shows the login and registration interface of the DeepSeek website. At the top is the DeepSeek logo. Below it, a message states: "您所在地区仅支持 邮箱 / Google / +86手机号 登录". There are two input fields: "请输入手机号/邮箱地址" (Please enter phone number/email address) and "请输入密码" (Please enter password). Below these is a checkbox for "我已阅读并同意 用户协议 与 隐私政策" (I have read and agree to the User Agreement and Privacy Policy). A blue "登录" (Login) button is present. Below the button are links for "忘记密码" (Forgot password) and "立即注册" (Register now). At the bottom, there is a section for "使用 Google 账号登录" (Login with Google account).

注册账户



聊天界面

基于ollama的本地run (macos或者linux)

❖ 安装ollama的包

- pip install ollama

❖ 基于ollama运行DeepSeek

– 运行1.5b模型

- ollama run deepseek-r1:1.5b

– 运行7b模型

- ollama run deepseek-r1:7b

– 运行8b模型

- ollama run deepseek-r1:8b

- ...

```
(base) lxx@lxxdeMacBook-Pro-2 models % ollama run deepseek-r1:1.5b
>>> 今天天气好吗
<think>

</think>
您好！首先，请将手机向我显示，这样我可以更好地为您服务。如果还有其他问题或需要帮助，请随时告诉我！

>>> 我有100万现金，可以给我一个理财方案吗
<think>
嗯，用户提到他今天天气好，然后问是否需要帮忙提供一个理财方案。这似乎有点混淆了，因为用户之前已经提到了天气问题，而这次又说有100万现金。

首先，我要弄清楚用户的意图到底是什么。表面上看，用户提供了一个关于理财的问题，询问是否有理财方案，但他的背景和问题可能有些混乱。他提到100万现金，这可能是他想投资或财富分配的一部分，但并没有明确说明是哪方面的。

另外，用户之前提到天气好，这似乎与理财无关，可能是一个打字错误或者混淆了主题。因此，我需要先澄清用户的真正需求，确定是否真的有100万现金，并且他对如何进行理财感兴趣。

如果用户确实想得到一个理财方案，而他提到了100万现金，那么我应该提供一些通用的建议或例子，比如分散投资、制定预算、优化投资组合等。当然，这些都是基于他的情况来推荐，但由于资金规模较大，建议可以更详细一点，比如具体的投资领域和个人风险承受能力。

在处理这类问题时，我需要保持谨慎，避免冒犯用户，同时确保信息的准确性和实用性。如果用户有其他问题或需要帮助解决实际问题，请随时告诉我，我会尽力提供帮助。
</think>

您好！您提到的“今天天气好吗”可能是一个打字错误或者混淆了主题。“我有100万现金，可以给我一个理财方案吗？”这看起来像是您的真实需求是想得到一个理财的建议或方案。不过，请您稍等一下，如果您确实有100万现金，并且对如何进行理财感兴趣，我很乐意为您提供一些建议。

**建议您以下内容**：

1. **明确目标和风险承受能力**：确定您希望投资的方向、期限以及您自身的财务承受能力。
2. **分散投资**：将资金分配到不同类型的资产，比如 stocks (股票)、bonds (债券) 或基金，以降低风险。
3. **制定长期规划**：考虑未来的职业规划、退休目标等，并为这些目标建立一个清晰的时间表。
4. **优化投资组合**：根据市场的状况和您的风险承受能力调整投资组合，平衡收益与风险。

如果您有更多具体问题，请随时告诉我，我会尽力为您提供一些建议。

>>>
>>> Send a message (/? for help)
```

```
(base) lxx@lxxdeMacBook-Pro-2 ~ % ollama run deepseek-r1:8b
pulling manifest
pulling 6340dc3229b0... 100% ██████████ 4.9 GB
pulling 369ca498f347... 100% ██████████ 387 B
pulling 6e4c38e1172f... 100% ██████████ 1.1 KB
pulling f4d24e9138dd... 100% ██████████ 148 B
pulling 0cb05c6e4e02... 100% ██████████ 487 B

verifying sha256 digest
writing manifest
success
>>> 我有100万现金，请给我一个低风险高收益的理财方案
<think>
嗯，我现在手头有100万现金，想做一些理财，但又不想冒太大的风险。听说有些投资方式风险低但收益高，这样比较适合我的情况。不过我不太清楚具体该怎么操作，所以得好好想一想。

首先，考虑一下分散投资。以前听朋友说过，如果把钱投到不同的地方，风险会降低。那100万现金，我可以把它分成几个部分来投资，比如买房、股票和债券，这样就不会有太大风险了。但具体怎么做呢？买房的话，是不是需要考虑房子的位置、租金情况等等。可能需要花点时间去看房或者找Property Manager管理，感觉这方面的工作量有点大。

然后是股票，我听说长期持有低估的蓝筹股可能会有不错的回报，而且有些公司还会分红，这样风险也不高。那我该怎么选择这些股票呢？有没有一些比较稳定的行业，比如消费品、医疗健康之类的。或者考虑指数基金，听说指数基金跟随大盘波动，小幅度波动可能风险低，但回报也可能一般。

接下来是债券，我觉得债券相对安全，因为是国债或者高评级的公司债，收益稳定。但现在利率可能在下降，所以是不是意味着债券的回报会变差呢？可能需要多了解一下市场情况，看看什么时候买债券比较划算。

还有基金和ETF，我觉得这也是一种分散投资的方式，不用自己去挑股票，可以通过定期投资来获取收益。但是要选择哪些基金或者ETF公司呢？听说一些大型的基金管理公司，比如Fidelity或Vanguard，历史业绩可能不错，而且费用也不太高，这样风险相对低一些。
```

DeepSeek 手机版的扫码安装和简单使用（手机里面使用）



DeepSeek的部署

- ❖ Deepseek系列模型包括V3（671b）、R1（660b）和基于DeepSeek-R1蒸馏的模型,如下表。
- ❖ 教育和科学领域任务需求，包括智能问答系统、学习辅助工具、数据分析助手、论文摘要生成等任务，可以基于deepseek搭建和部署本地的小模型环境。

- ❖ DeepSeekR1蒸馏版均可进行本地化部署。
- ❖ 小规模1.5b-8b的可部署在普通机，其余需要GPU。
- ❖ 全量版MoE671b：无法直接本地部署，但有压缩的动态量化版本实现本地化，需高端GPU服务器。

模型版本	显存 VRAM (GPU)	内存 RAM (CPU)	本地存储	运行机器
R1-1.5b	4GB+	8GB+	5 GB	个人普通机
R1-7b	12GB+	16GB+	10 GB	个人普通机
R1-8b	16GB+	32GB+	15 GB	个人普通机 专用
R1-14b	24GB+	64GB+	30 GB	服务器 GPU服务
R1-32b	48GB+	128GB+	60 GB	器 GPU服务器
R1-70b	80GB+	256GB+	120GB	高端GPU服务器
V3\R1-671B (MoE)	4*A100 GPUs (320GB VRAM)	(512GB	500GB+	

DeepSeek部署的前期准备-机器环境

❖ TO-C (个人)

❖ 机器：个人笔记本、台式机


❖ 选择版本：1.5b、7b、8b

❖ 配置要求：

- 内存：建议16GB以上
- CPU 性能越好，有带GPU更好
- 根据配置选择部署的大模型版本：1.5b、7b、8b、14b或更高版本
- 普通电脑1.5b的效果不错

❖ 操作系统：Windows、Linux、MacOS

❖ 软件：python及相关的包、库等。



❖ To-B (单位)

❖ 单位：服务器或基础设施（带GPU）

❖ 选择版本：14b、32b、70b

❖ 配置要求：

- 内存：建议64GB以上
- CPU 性能越好，有带GPU更好
- 根据配置选择部署的大模型版本
- 操作系统：Linux


❖ 软件：python及相关的包、库等。




在Window上安装Deepseek

Ollama的本地化部署-下载和安装【速度超级快】





<http://www.ollama.com>



windows下
DeepSeek的部
署



DeepSeek本地服务的安装



Deepseek模型的本地运行和使用-ollama [windows的命令行运行]

```
C:\WINDOWS\system32\cmd. X + v
(c) Microsoft Corporation. 保留所有权利。

C:\Users\C>ollama
Usage:
  ollama [flags]
  ollama [command]

Available Commands:
  serve      Start ollama
  create     Create a model from a Modelfile
  show       Show information for a model
  run        Run a model
  stop       Stop a running model
  pull       Pull a model from a registry
  push       Push a model to a registry
  list       List models
  ps         List running models
  cp         Copy a model
  rm         Remove a model
  help       Help about any command

Flags:
  -h, --help      help for ollama
  -v, --version    Show version information

Use "ollama [command] --help" for more information about a command.

C:\Users\C>ollama run deepseek-r1:1.5b
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling aabd4deb0c8... 45% | 498 MB/1.1 GB 5.3 MB/s 1m55s
```

模型正在下载

```
C:\WINDOWS\system32\cmd. X + v
Available Commands:
  serve      Start ollama
  create     Create a model from a Modelfile
  show       Show information for a model
  run        Run a model
  stop       Stop a running model
  pull       Pull a model from a registry
  push       Push a model to a registry
  list       List models
  ps         List running models
  cp         Copy a model
  rm         Remove a model
  help       Help about any command

Flags:
  -h, --help      help for ollama
  -v, --version    Show version information

Use "ollama [command] --help" for more information about a command.

C:\Users\C>ollama run deepseek-r1:1.5b
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling aabd4deb0c8... 100% | 1.1 GB
pulling 369ca498f347... 100% | 387 B
pulling 6e4c38e1172f... 100% | 1.1 KB
pulling f4d24e9138dd... 100% | 148 B
pulling a85fe2a2e58e... 100% | 487 B
verifying sha256 digest
writing manifest
success
>>> Send a message (/? for help)
```

DeepSeek-R1:1.5b
的模型下载完毕

```
C:\WINDOWS\system32\cmd. X + v
Flags:
  -h, --help      help for ollama
  -v, --version    Show version information

Use "ollama [command] --help" for more information about a command.

C:\Users\C>ollama run deepseek-r1:1.5b
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling manifest
pulling aabd4deb0c8... 100% | 1.1 GB
pulling 369ca498f347... 100% | 387 B
pulling 6e4c38e1172f... 100% | 1.1 KB
pulling f4d24e9138dd... 100% | 148 B
pulling a85fe2a2e58e... 100% | 487 B
verifying sha256 digest
writing manifest
success
>>> 您好
<think>

</think>

你好！很高兴见到你，有什么我可以帮忙的吗？无论是聊天、解答问题还是提供建议，我都在这里哦！😊

>>> 您是谁啊
<think>

</think>


您好！我是由中国的深度求索（DeepSeek）公司开发的智能助手 DeepSeek-R1。如您有任何任何问题，我会尽我所能为您提供帮助。

>>> Send a message (/? for help)
```

DeepSeek模型使用对话

DeepSeek本地版-基于Page Assist for Ollama (网页版)

- ❖ Page Assist是浏览器插件，基于本地AI模型的Web UI工具，可视化的模型对话，提供便捷的交互界面，支持视觉模型和文档交流功能
- ❖ Page Assist for Ollama官网入口网址: <https://openi.cn/sites/143085.html>, 下载插件: <https://www.chajianxw.com/product-tool/85997.html>





Page Assist的使用



大模型的幻觉问题

➤ 大模型或小模型，都存在生成的内容不准确、不完整或误导性的现象




大模型的幻觉问题

➤ 蒸馏、微调和RAG (Retrieval-Augmented Generation)

为了赋予模型某个领域的特定知识，解决大模型的幻觉问题


这是蒸馏

这题我不会，但是在老师的辅导下，看了老师的解题思路和答案，我顿悟了，以后这类题我都会




这是微调

这题我不会，但是我找到了参考书，通过自学参考书，我也顿悟了，以后这类题我也会



这是RAG

这题我不会，考试的时候我带了小抄，通过看小抄，我也能正确答题，但下次如果没小抄我还是不会~



大模型的幻觉问题


➤ RAG (Retrieval-Augmented Generation) 的原理

- **检索**(Retrieval): 当用户提出问题时, 系统会从外部的知识库中检索出与用户输入相关的内容
- **增强**(Augmentation): 系统将检索到的信息与用户的输入结合, 扩展模型的上下文。然后再传给生成模型(也就是Deepseek)
- **生成**(Generation): 生成模型基于增强后的输入生成最终的回答。由于这一回答参考了外部知识库中的内容, 因此更加准确可读

➤ Page Assist 中RAG设置



➤ 可以上传自己的本地文档作为知识库



➤ 上传解析完成，得到向量化的知识库

<

📄

📝 新聊天

...

/

🦋 deepseek-r1:1.5b

▼

/

选择一个提示词

▼

✅ 知识添加成功

⚙️

🔖

⚙️

🔧 一般设置

🔧 RAG 设置

🦋 Ollama 设置

🔧 Chrome AI 设置 Beta

🔧 OpenAI 兼容 API Beta

🔧 管理模型

📁 管理知识

📄 管理提示词

📤 管理共享

📄 关于

➕

金融知识

🟡 处理中

deepseek-r1:1.5b

2025/6/13 20:11:49

🗑️

<

1

>

➕ 添加新知识

在Mac上安装Deepseek

➤ 在ollama官网下载macos版本

[Discord](#)[GitHub](#)[Models](#)[Sign in](#)[Download](#)

Download Ollama



macOS



Linux



Windows


Download for macOS

Requires macOS 11 Big Sur or later


While Ollama downloads, sign up to get notified of new updates.

Get updates

➤ 下载Anything LLM并进行配置



➤ 上传本地文件得到本地知识库



➤ 构建完自己的知识库后，尝试使用，查看问答效果

vl.8.2

Anything LLM

+ 新工作区

Test

论文

default

+ New Thread

test

股骨头坏死的检测过程

嗯，用户问的是“股骨头坏死的检测过程”。首先，我需要理解什么是股骨头坏死。股骨头坏死是一种常见的软组织病，通常发生在股神经末梢受损时。患者可能表现为股骨硬化、疼痛和活动受限等症状。

接下来，我要分析用户的需求。用户希望了解股骨头坏死的检测过程，这可能涉及到临床诊断、影像学检测以及机器学习方法等。作为医学图像专家，我需要确保回答全面且准确。

根据提供的上下文，文档中提到了上海大学的学位论文内容，包括基于深度学习的方法。这部分可能对检测过程有帮助，但用户可能更关注的是实际操作步骤和步骤。

在回答时，我应该分步骤详细说明：第一步是患者的情况评估，如症状、体征和影像特征；第二步是临床诊断，结合患者体征和影像学结果进行初步判断；第三步则是机器学习方法的集成应用，包括多模态数据处理和深度神经网络的应用。

最后，考虑到用户可能需要实际操作指南，我应该给出一些实用技巧，如影像选取、分类分析、特征提取等，并建议使用现有的医学图像软件工具。

整个过程中，我要确保回答清晰易懂，同时结合上下文中的关键信息，帮助用户全面了解股骨头坏死的检测过程。

股骨头坏死是一种常见的软组织病，其症状通常表现为股骨硬化、疼痛、活动受限等症状。在临床情况下，医生会通过体征检查和影像学检测来评估股骨头坏死的发生情况。以下是对股骨头坏死检测过程的详细说明：

1. 患者的基本情况

病史：患者可能患有股骨硬化病、股骨坏死症或其他类似症状。

发送消息

Deepseek本地化部署 + RAG教程链接

- Windows版

<https://zhuanlan.zhihu.com/p/22375430266>

https://blog.csdn.net/qq_34418186/article/details/145475140

- Mac OS版

https://www.bilibili.com/video/BV1JWATeHEvD/?vd_source=1f9b34010ba3b864b26af26c67c36f40

写在最后



2025年9月新学期
将面向全校大一和研一开设《人工智能基础》课程